Codul analizei MQTTset

Scripturile care reproduc toate cifrele și graficele din document. Repo: https://github.com/Darius15222/mqtt-attack-analysis (folderul cod/); site: https://darius15222.github.io/mqtt-attack-analysis/

Rulare: `python3 -m venv venv && venv/bin/pip install pandas scipy statsmodels mlxtend matplotlib`, apoi `venv/bin/python 01_cap1-7_statistici_corelatii.py mqttdataset_reduced.csv.zip`. Arborii: `Rscript 09_cap10_arbori_ctree.R mqttdataset_reduced.csv.zip arbori` (pachetul R partykit).

1. `01_cap1-7_statistici_corelatii.py`
2. `02_cap7-9_regresii_logistica.py`
3. `03_cap9_probabilitati.py`
4. `04_cap9_firth.py`
5. `05_cap8-9_cook_durbin_watson.py`
6. `06_cap11_reguli_asociere.py`
7. `07_grafice_corelatie.py`
8. `08_grafice_restul.py`
9. `09_cap10_arbori_ctree.R`
10. `10_grafice_arbori.py`

01_cap1-7_statistici_corelatii.py

```python
"""Statistici descriptive, teste și corelații pentru MQTTset (cap. 1-7 din raport).

Reproduce cifrele din:
  - distribuția claselor și coloanele constante;
  - statisticile descriptive (cap. 5) și valorile extreme după regula IQR;
  - tabelul pe clase, testul Kruskal-Wallis, χ² pe tcp.flags și mqtt.conack.val,
    testul Mann-Whitney flood vs. legitimate (cap. 6);
  - corelațiile Spearman/Pearson și verificările din cap. 7;
  - exemplele de rânduri și tabelul cu valori tipice normal/atac (cap. 3).

Intrare:  fișierul CSV MQTTset (merge și .zip, pandas îl citește direct).
Ieșire:   doar text la stdout.

Rulare:
    python 01_cap1-7_statistici_corelatii.py ../mqttdataset_reduced.csv.zip
"""
import sys

import pandas as pd
from scipy import stats

date = pd.read_csv(sys.argv[1], low_memory=False)

# Cele 13 coloane numerice folosite în matricea de corelație (cap. 7).
COLOANE_NUMERICE = [
    "tcp.time_delta", "tcp.len", "mqtt.len", "mqtt.kalive", "mqtt.qos",
    "mqtt.dupflag", "mqtt.retain", "mqtt.conflag.cleansess", "mqtt.conflag.passwd",
    "mqtt.conflag.uname", "mqtt.proto_len", "mqtt.ver", "mqtt.conack.val",
]

# Indicatorii binari / aproape constanți: îi descriem prin procentul de valori nenule.
INDICATORI = [
    "mqtt.dupflag", "mqtt.retain", "mqtt.conflag.cleansess", "mqtt.conflag.passwd",
    "mqtt.conflag.uname", "mqtt.proto_len", "mqtt.ver", "mqtt.conack.val", "mqtt.qos",
]

# --- Cap. 1-3: dimensiunea setului, clasele, coloanele constante ---
print(date.shape)
print(date.target.value_counts(), (date.target.value_counts(normalize=True) * 100).round(2))

coloane_constante = [c for c in date if date[c].nunique() == 1]
print("const", len(coloane_constante), coloane_constante)

# --- Cap. 5: statistică descriptivă pentru coloanele continue ---
for coloana in ["tcp.len", "tcp.time_delta", "mqtt.len", "mqtt.kalive"]:
    x = date[coloana]
    print(coloana,
          "mean", round(x.mean(), 2),
          "std", round(x.std(), 2),
          "med", x.median(),
          "q", x.quantile([.25, .75]).tolist(),
          "skew", round(x.skew(), 2),
          "kurt", round(x.kurt(), 1))

    # Valori extreme după regula IQR: în afara [Q1 - 1,5·IQR, Q3 + 1,5·IQR].
    q1, q3 = x.quantile([.25, .75])
    iqr = q3 - q1
    prag_sus = q3 + 1.5 * iqr
    extreme = (x < q1 - 1.5 * iqr) | (x > prag_sus)
    print("  IQR: peste", prag_sus,
          "n", extreme.sum(),
          round(extreme.mean() * 100, 2), "%",
          date.target[extreme].value_counts(normalize=True).round(3).to_dict())

# Coloanele categoriale: valoarea cea mai frecventă și ponderea ei.
# Le citim ca text pentru că amestecă numere ("0") cu valori hex ("0x00000010") și NaN.
for coloana in ["tcp.flags", "mqtt.hdrflags", "mqtt.msgtype", "mqtt.conflags",
                "mqtt.protoname", "mqtt.conack.flags", "mqtt.msg"]:
    frecvente = date[coloana].astype(str).value_counts(normalize=True)
    print(coloana, frecvente.index[0], round(frecvente.iloc[0] * 100, 2))

```

```
for coloana in INDICATORI:
    nenule = date[coloana] != 0
    print(coloana, "nonzero%", round(nenule.mean() * 100, 2), "count", nenule.sum(),
          date[coloana].unique()[:6])

# --- Cap. 6: comparații pe clase ---
legitim = date[date.target == "legitimate"]
tcp_len_legitim = legitim["tcp.len"]
print("leg tcp.len med q", tcp_len_legitim.median(), tcp_len_legitim.quantile([.25, .75]).tolist(),
      "mean", round(tcp_len_legitim.mean(), 2),
      "zero%", round((tcp_len_legitim == 0).mean() * 100, 1),
      "10-14%", round(tcp_len_legitim.between(10, 14).mean() * 100, 1))

# Mediana și quartilele pe clase, apoi Kruskal-Wallis (date puternic asimetrice, deci test neparametric).
for coloana in ["tcp.time_delta", "tcp.len", "mqtt.len"]:
    pe_clase = date.groupby("target")[coloana]
    print(coloana, {clasa: (g.median(), g.quantile(.25), g.quantile(.75)) for clasa, g in pe_clase})
    print(" KW H", stats.kruskal(*[g.values for _, g in pe_clase]))

for coloana in ["tcp.flags", "mqtt.hdrflags", "mqtt.msgtype"]:
    for clasa, grup in date.groupby("target"):
        frecvente = grup[coloana].astype(str).value_counts(normalize=True)
        print(" ", coloana, clasa, frecvente.index[0], round(frecvente.iloc[0] * 100, 2))

for coloana in ["mqtt.dupflag", "mqtt.retain", "mqtt.conflag.cleansess", "mqtt.conflag.passwd",
                "mqtt.conflag.uname", "mqtt.conack.val", "mqtt.qos"]:
    procent_nenule = date.groupby("target")[coloana].apply(lambda s: (s != 0).mean() * 100)
    print(coloana, procent_nenule.round(2).to_dict())

# 65535 = keep-alive maxim din MQTT, specific atacului slowite.
print("kalive slowite 65535%",
      round((date[date.target == "slowite"]["mqtt.kalive"] == 65535).mean() * 100, 2),
      date["mqtt.kalive"].unique()[:10])

# Testul χ² de independență: tcp.flags × clasă.
observate = pd.crosstab(date["tcp.flags"], date.target)
print(observate)
chi2_flags = stats.chi2_contingency(observate)
print("chi2", chi2_flags[0], chi2_flags[2])
asteptate = chi2_flags[3]
print("E FIN,ACK bf",
      asteptate[observate.index.get_loc("0x00000011"), observate.columns.get_loc("bruteforce")])

# Testul χ² pentru mqtt.conack.val × clasă (și frecvențele așteptate).
observate_conack = pd.crosstab(date["mqtt.conack.val"], date.target)
chi2_conack = stats.chi2_contingency(observate_conack)
print(observate_conack, "chi2", chi2_conack[0])
print("E", chi2_conack[3])

# Mann-Whitney pe tcp.time_delta: legitimate vs. flood, în ambele ordini (U se schimbă cu ordinea).
delta_legitim = legitim["tcp.time_delta"]
delta_flood = date[date.target == "flood"]["tcp.time_delta"]
print("MW", stats.mannwhitneyu(delta_legitim, delta_flood), len(delta_legitim) * len(delta_flood))
print("MW flipped", stats.mannwhitneyu(delta_flood, delta_legitim))

# --- Cap. 4: rânduri de exemplu (numerotate de la 1, ca în CSV) ---
for clasa in date.target.unique():
    print(clasa, list(date.index[date.target == clasa][:2] + 1))
print(date.loc[[0, 4, 1, 46, 36, 6, 1420], ["tcp.flags", "tcp.len", "mqtt.len", "target"]])

# --- Cap. 7: corelații Spearman / Pearson ---
spearman = date[COLOANE_NUMERICE].corr("spearman")
print(spearman.round(2))

date["is_attack"] = (date.target != "legitimate").astype(int)
perechi = [
    ("tcp.len", "mqtt.len"), ("tcp.time_delta", "tcp.len"), ("tcp.time_delta", "mqtt.len"),
    ("tcp.len", "is_attack"), ("mqtt.len", "is_attack"), ("tcp.time_delta", "is_attack"),
    ("mqtt.qos", "is_attack"), ("mqtt.dupflag", "is_attack"),
]
for a, b in perechi:
    print(a, b, round(date[a].corr(date[b]), 3), round(date[a].corr(date[b], method="spearman"), 3))

# Câmpurile de conectare (mqtt.ver, mqtt.kalive) sunt nenule exact pe aceleași rânduri.
```

```
ver_nenul = date["mqtt.ver"] != 0
print("conn nonzero rows", ver_nenul.sum(), (ver_nenul == (date["mqtt.kalive"] != 0)).all())

qos1 = date[date["mqtt.qos"] == 1]
print("qos1", len(qos1), qos1.target.unique(), qos1["mqtt.len"].min(), qos1["mqtt.len"].max(),
      date[date["mqtt.qos"] == 0]["mqtt.len"].mean())
# dupflag = 1 apare doar pe rânduri cu qos = 1 (rezultatul așteptat e 0).
print("dup1 subset qos1", ((date["mqtt.dupflag"] == 1) & (date["mqtt.qos"] != 1)).sum())

for clasa, grup in date.groupby("target"):
    constante_in_clasa = [c for c in COLOANE_NUMERICE if grup[c].nunique() == 1]
    print(clasa, "tcp-mqtt spearman",
          round(grup["tcp.len"].corr(grup["mqtt.len"], method="spearman"), 2),
          "nconst", len(constante_in_clasa), constante_in_clasa)

flood = date[date.target == "flood"]
print("tcp.len max flood", flood["tcp.len"].max(), "mqtt.len flood max", flood["mqtt.len"].max())

# Sumele din formula coeficientului Pearson, calculate de mână pentru exemplul din raport.
x = date["tcp.len"]
y = date["mqtt.len"]
print("sxy", ((x - x.mean()) * (y - y.mean())).sum(),
      "sxx", ((x - x.mean()) ** 2).sum(),
      "syy", ((y - y.mean()) ** 2).sum())

# --- Cap. 3: tabelul cu valori tipice „normal” vs. „atac” ---
# Pentru atac luăm cea mai frecventă valoare care apare (aproape) numai în atacuri:
# cel puțin 99% din rândurile cu acea valoare sunt atacuri.
atacuri = date[date.is_attack == 1]
for coloana in ["tcp.flags", "tcp.time_delta", "tcp.len", "mqtt.hdrflags", "mqtt.msgtype",
                "mqtt.len", "mqtt.qos", "mqtt.dupflag", "mqtt.kalive"]:
    valori_text = date[coloana].astype(str)
    pondere_atac = date.groupby(valori_text)["is_attack"].mean()
    valori_de_atac = pondere_atac[pondere_atac >= 0.99].index

    frecvente_atac = atacuri[coloana].astype(str).value_counts()
    frecvente_atac = frecvente_atac[frecvente_atac.index.isin(valori_de_atac)]
    frecvente_normal = legitim[coloana].astype(str).value_counts(normalize=True)

    if len(frecvente_atac):
        exemplu_atac = (frecvente_atac.index[0], round(frecvente_atac.iloc[0] / len(atacuri) * 100, 1))
    else:
        exemplu_atac = None
    print("T4", coloana,
          "normal", frecvente_normal.index[0], round(frecvente_normal.iloc[0] * 100, 1),
          "attack", exemplu_atac)
```

02_cap7-9_regresii_logistica.py

```python
"""Corelații pe clase, regresii liniare, VIF și regresie logistică pentru MQTTset (cap. 7-9).

Reproduce cifrele din:
  - matricea Spearman pe tot setul și pe fiecare clasă (cap. 7);
  - verificările pe flood / tcp.len > 1460 și valorile maxime (cap. 8);
  - regresiile liniare 1-3, inclusiv variantele logaritmice (cap. 8-9);
  - VIF pentru 5 și 3 predictori;
  - regresia logistică: modelul final cu 3 predictori, separarea modelului cu 5 predictori
    (pașii 10-30), probabilitățile prezise pe clase, tabelul 9.2, msgtype pe clase (cap. 9).

Intrare:  fișierul CSV MQTTset (merge și .zip, pandas îl citește direct).
Ieșire:   doar text la stdout.

Rulare:
    python 02_cap7-9_regresii_logistica.py ../mqttdataset_reduced.csv.zip
"""
import sys

import numpy as np
import pandas as pd
import statsmodels.api as sm
from scipy import stats
from statsmodels.stats.outliers_influence import variance_inflation_factor as vif

date = pd.read_csv(sys.argv[1], low_memory=False)
date["is_attack"] = (date.target != "legitimate").astype(int)

# Cele 13 coloane numerice folosite în matricea de corelație (cap. 7).
COLOANE_NUMERICE = [
    "tcp.time_delta", "tcp.len", "mqtt.len", "mqtt.kalive", "mqtt.qos",
    "mqtt.dupflag", "mqtt.retain", "mqtt.conflag.cleansess", "mqtt.conflag.passwd",
    "mqtt.conflag.uname", "mqtt.proto_len", "mqtt.ver", "mqtt.conack.val",
]
PREDICTORI_5 = ["tcp.len", "mqtt.len", "tcp.time_delta", "mqtt.qos", "mqtt.dupflag"]
PREDICTORI_3 = ["tcp.len", "tcp.time_delta", "mqtt.len"]

# --- Cap. 7: matricea Spearman ---
pd.set_option("display.width", 250)  # ca matricea 13×13 să încapă pe un rând
spearman = date[COLOANE_NUMERICE].corr("spearman")
print(spearman.round(2).to_string())

# Pe fiecare clasă: câte perechi de coloane sunt practic identice (ρ ≥ 0,995).
# Coloanele constante în clasă sunt scoase, altfel corelația lor e NaN.
for clasa, grup in date.groupby("target"):
    coloane_variabile = [c for c in COLOANE_NUMERICE if grup[c].nunique() > 1]
    matrice = grup[coloane_variabile].corr("spearman").values
    deasupra_diagonalei = np.triu_indices(len(coloane_variabile), 1)
    print(clasa,
          "pairs", len(deasupra_diagonalei[0]),
          "r>=0.995", (matrice[deasupra_diagonalei] >= 0.995).sum())

print("pearson qos-mqtt.len", date["mqtt.qos"].corr(date["mqtt.len"]))

# --- Cap. 8: verificări pe flood și pe valorile mari ---
# 1460 = payload-ul TCP maxim într-un cadru Ethernet (MSS tipic).
flood = date[date.target == "flood"]
print("flood mqtt.len when tcp.len>1460", flood[flood["tcp.len"] > 1460]["mqtt.len"].describe().to_dict())
print("flood ACK empty", ((flood["tcp.flags"] == "0x00000010") & (flood["tcp.len"] == 0)).sum(),
      "tcp.len>1460 all", (date["tcp.len"] > 1460).sum(),
      date[date["tcp.len"] > 1460].target.unique())
print("legit tcp.len max", date[date.target == "legitimate"]["tcp.len"].max(),
      "time_delta max", date["tcp.time_delta"].max(),
      (date["tcp.time_delta"] > 50).sum())

# --- Regresia 1: mqtt.len ~ tcp.len (simplă și pe log(1 + x)) ---
regresia1 = sm.OLS(date["mqtt.len"], sm.add_constant(date[["tcp.len"]])).fit()
print("R1", regresia1.params.round(4).to_dict(), round(regresia1.rsquared, 4),
      "ssr", regresia1.ssr,
      "res skew/kurt", round(stats.skew(regresia1.resid), 2), round(stats.kurtosis(regresia1.resid), 1))

date_log = np.log1p(date[["tcp.len", "mqtt.len"]])  # log1p pentru că există multe valori 0
```

```
regresia1_log = sm.OLS(date_log["mqtt.len"], sm.add_constant(date_log["tcp.len"])).fit()
print("R1log", regresia1_log.params.round(3).to_dict(), round(regresia1_log.rsquared, 3),
      round(stats.skew(regresia1_log.resid), 2), round(stats.kurtosis(regresia1_log.resid), 1))

# --- Regresia 2: tcp.time_delta ~ tcp.len + mqtt.len ---
regresia2 = sm.OLS(date["tcp.time_delta"], sm.add_constant(date[["tcp.len", "mqtt.len"]])).fit()
print("R2", regresia2.params.to_dict(), regresia2.pvalues.to_dict(), regresia2.rsquared,
      stats.skew(regresia2.resid), stats.kurtosis(regresia2.resid))

# --- Regresia 3: regresia 1 pe fiecare clasă (simplă și logaritmică) ---
for clasa, grup in date.groupby("target"):
    simpla = sm.OLS(grup["mqtt.len"], sm.add_constant(grup["tcp.len"])).fit()
    grup_log = np.log1p(grup[["tcp.len", "mqtt.len"]])
    logaritmica = sm.OLS(grup_log["mqtt.len"], sm.add_constant(grup_log["tcp.len"])).fit()
    print("R3", clasa, len(grup), simpla.params.round(4).tolist(),
          round(simpla.rsquared, 3), round(logaritmica.rsquared, 3))

# Concluzia cap. 8: cât din fiecare clasă stă la cel mult 2 bytes de dreapta traficului normal.
normal = date[date.target == "legitimate"]
dreapta_normal = sm.OLS(normal["mqtt.len"], sm.add_constant(normal["tcp.len"])).fit().params
distanta = (date["mqtt.len"] - (dreapta_normal["const"] + dreapta_normal["tcp.len"] * date["tcp.len"])).abs
()
print("R3 pe dreapta normalului (<= 2 bytes, %)", (distanta <= 2).groupby(date.target).mean().mul(100).round
(1).to_dict())

# --- VIF (multicoliniaritate); indicele 0 e constanta, deci pornim de la 1 ---
X5 = sm.add_constant(date[PREDICTORI_5]).values
print("VIF5", [round(vif(X5, i), 2) for i in range(1, 6)])
X3 = sm.add_constant(date[PREDICTORI_3]).values
print("VIF3", [round(vif(X3, i), 2) for i in range(1, 4)])

# --- Cap. 9: regresia logistică is_attack ~ 3 predictori (modelul final) ---
logistica3 = sm.GLM(date.is_attack, sm.add_constant(date[PREDICTORI_3]),
                    family=sm.families.Binomial()).fit()
print("LOG6", logistica3.params.round(4).to_dict(), logistica3.bse.round(4).to_dict(),
      logistica3.tvalues.round(2).to_dict(),
      logistica3.null_deviance, logistica3.deviance, logistica3.aic,
      "iters", logistica3.fit_history["iteration"])

# Modelul cu 5 predictori are separare cvasi-completă (qos = 1 și dupflag = 1 doar la atac):
# coeficienții și erorile standard cresc
# la fiecare pas. tol=1e-30 împiedică oprirea timpurie, ca să vedem pașii 10-30.
for nr_pasi in [10, 15, 20, 25, 30]:
    logistica5 = sm.GLM(date.is_attack, sm.add_constant(date[PREDICTORI_5]),
                        family=sm.families.Binomial()).fit(maxiter=nr_pasi, tol=1e-30)
    print("LOG5 it", nr_pasi, logistica5.params.round(3).to_dict(), logistica5.bse.round(1).to_dict(),
          round(logistica5.deviance, 1))

# Probabilitățile prezise de modelul final, pe clase.
# „~0.42” = ponderea rândurilor cu probabilitatea ≈ 0,4235 (valoarea discutată în 9.6).
probabilitati = pd.Series(logistica3.predict(), index=date.index)
for clasa in date.target.unique():
    p = probabilitati[date.target == clasa]
    print("prob", clasa,
          "max", round(p.max(), 3),
          "med", round(p.median(), 3),
          ">0.9", round((p > 0.9).mean(), 3),
          "~0.42", round((np.abs(p - 0.4235) < 0.005).mean(), 3))

# --- Tabelul 9.2: mediana și quartilele pentru atacuri ---
atacuri = date[date.is_attack == 1]
for coloana in ["tcp.time_delta", "tcp.len", "mqtt.len"]:
    print("9.2", coloana, atacuri[coloana].median(), atacuri[coloana].quantile([.25, .75]).tolist())

print("msgtype by class", pd.crosstab(date["mqtt.msgtype"], date.target).to_string())
```

03_cap9_probabilitati.py

```python
"""Probabilitățile prezise de regresia logistică și verificările din cap. 9 pentru MQTTset.

Reproduce cifrele din:
  - 9.6: probabilitățile prezise pe clase și curva logistică pentru un pachet tipic;
  - tabelul 9.2: mediana și quartilele pentru atacuri;
  - mqtt.msgtype pe clase și pachetele PUBLISH+ACK din dos;
  - câteva calcule de verificare citate în text (tcp.time_delta = 3e-6,
    exemplul de asimetrie/aplatizare, contribuția χ² pentru conack).

Intrare:  fișierul CSV MQTTset (merge și .zip, pandas îl citește direct).
Ieșire:   doar text la stdout.

Rulare:
    python 03_cap9_probabilitati.py ../mqttdataset_reduced.csv.zip
"""
import sys

import numpy as np
import pandas as pd
import statsmodels.api as sm

date = pd.read_csv(sys.argv[1], low_memory=False)
date["is_attack"] = (date.target != "legitimate").astype(int)

# --- 9.6: modelul logistic final și probabilitățile prezise pe clase ---
model = sm.GLM(date.is_attack, sm.add_constant(date[["tcp.len", "tcp.time_delta", "mqtt.len"]]),
               family=sm.families.Binomial()).fit()
probabilitati = pd.Series(np.asarray(model.predict()), index=date.index)
for clasa in date.target.unique():
    p = probabilitati[date.target == clasa]
    print("prob", clasa,
          "max", round(p.max(), 3),
          "med", round(p.median(), 3),
          ">0.9", round((p > 0.9).mean(), 3),
          "~0.42", round((np.abs(p - 0.4235) < 0.005).mean(), 3))

# Probabilitatea pentru un pachet tipic: tcp.len = 13, mqtt.len = 11, tcp.time_delta = 0.
coef = model.params
print("curve d=0 typical", 1 / (1 + np.exp(-(coef.const + coef["tcp.len"] * 13 + coef["mqtt.len"] * 11))))

# --- Tabelul 9.2: mediana și quartilele pentru atacuri ---
atacuri = date[date.is_attack == 1]
for coloana in ["tcp.time_delta", "tcp.len", "mqtt.len"]:
    print("9.2", coloana, atacuri[coloana].median(), atacuri[coloana].quantile([.25, .75]).tolist())

# --- mqtt.msgtype pe clase ---
print(pd.crosstab(date["mqtt.msgtype"], date.target).to_string())

# Pachetele dos de tip PUBLISH (msgtype 3) cu flag-ul TCP ACK (0x10).
dos_publish_ack = date[(date.target == "dos")
                       & (date["mqtt.msgtype"] == 3)
                       & (date["tcp.flags"] == "0x00000010")]
print("dos publish ACK", len(dos_publish_ack), dos_publish_ack["tcp.len"].unique()[:5],
      "70%", round(len(dos_publish_ack) * .7))

# --- Verificări pentru cifre citate în text ---
print("time_delta =3e-6 share", (date["tcp.time_delta"] == 3e-6).mean(),
      "<=3e-6", (date["tcp.time_delta"] <= 3e-6).mean())

# Exemplul mic de asimetrie și aplatizare din raport.
exemplu = pd.Series([1, 2, 2, 3, 10])
print(exemplu.skew(), exemplu.kurt())

# Contribuția unei celule la χ²: (O - E)² / E, cu O = 1428 și E = 62,5742.
print("conack contrib", (1428 - 62.5742) ** 2 / 62.5742)
```

04_cap9_firth.py

```python
"""
Regresia logistică Firth (cap. 9.5 din tema MQTTset).

Reproduce: coeficienții, erorile standard, statisticile Chisq
(testul raportului de verosimilitate penalizată) pentru fiecare predictor
și testele globale (Likelihood ratio și Wald, pe toți cei 5 predictori).

Intrare:  CSV-ul MQTTset (sau arhiva .zip, pandas o citește direct).
Ieșire:   doar text la consolă.

Rulare:
    python 04_cap9_firth.py ../mqttdataset_reduced.csv.zip

Firth este implementat manual (numpy), fără pachete suplimentare.
Motivul folosirii Firth: datele au separare (aproape) completă, iar regresia
logistică obișnuită dă coeficienți care fug la infinit. Penalizarea Firth
ține coeficienții finiți.
"""
import sys

import numpy as np
import pandas as pd

# ---------------------------------------------------------------
# Date: y = 1 pentru orice atac, 0 pentru trafic legitim
# ---------------------------------------------------------------
PREDICTORI = ["tcp.len", "mqtt.len", "tcp.time_delta", "mqtt.qos", "mqtt.dupflag"]

date = pd.read_csv(sys.argv[1], low_memory=False, usecols=PREDICTORI + ["target"])
y = (date.target != "legitimate").values.astype(float)
# prima coloană = 1, pentru interceptul modelului
X = np.column_stack([np.ones(len(date)), date[PREDICTORI].values])


# ---------------------------------------------------------------
# Algoritmul Firth
# ---------------------------------------------------------------
def verosimilitate_penalizata(X, y, beta):
    """Log-verosimilitatea penalizată Firth: log L(beta) + 0.5 * log det I(beta).

    Întoarce și p (probabilitățile), w = p(1-p) și matricea de informație I,
    care sunt refolosite de pasul Newton.
    """
    eta = np.clip(X @ beta, -500, 500)  # clip ca exp() să nu dea overflow
    p = 1 / (1 + np.exp(-eta))
    w = p * (1 - p)
    informatie = (X * w[:, None]).T @ X  # I = X' W X
    # 1e-300 evită log(0) când p ajunge exact 0 sau 1
    log_verosimilitate = np.sum(y * np.log(p + 1e-300) + (1 - y) * np.log(1 - p + 1e-300))
    penalizare = 0.5 * np.linalg.slogdet(informatie)[1]
    return log_verosimilitate + penalizare, p, w, informatie


def ajusteaza_firth(X, y, coef_fixat=None, max_iteratii=200):
    """Estimează coeficienții Firth prin Newton-Raphson cu înjumătățirea pasului.

    coef_fixat: indicele (sau lista de indici) coeficienților ținuți la 0
    (pentru modelul restrâns din testele Chisq și Likelihood ratio). Întoarce (coeficienți, erori standard,
log-verosimilitate
    penalizată).

    Pașii unei iterații:
      1. calculăm p, W și I = X'WX în punctul curent;
      2. h = diagonala matricei hat H = W^(1/2) X I^-1 X' W^(1/2);
      3. scorul modificat Firth: U = X' (y - p + h (0.5 - p));
      4. pasul Newton: I^-1 U (doar pe coeficienții liberi);
      5. înjumătățim pasul până când verosimilitatea penalizată nu scade.
    """
    beta = np.zeros(X.shape[1])
    liber = np.ones(X.shape[1], bool)
    if coef_fixat is not None:
```

```
        liber[coef_fixat] = False  # rămân la valoarea de start, 0

    for _ in range(max_iteratii):
        L, p, w, informatie = verosimilitate_penalizata(X, y, beta)
        informatie_inv = np.linalg.inv(informatie)
        h = w * np.einsum("ij,jk,ik->i", X, informatie_inv, X)
        scor = X.T @ (y - p + h * (0.5 - p))
        informatie_libera = informatie[np.ix_(liber, liber)]
        pas = np.linalg.solve(informatie_libera, scor[liber])

        factor = 1.0
        while True:
            beta_nou = beta.copy()
            beta_nou[liber] += factor * pas
            if verosimilitate_penalizata(X, y, beta_nou)[0] >= L - 1e-9 or factor < 1e-4:
                break
            factor /= 2
        beta = beta_nou

        if np.max(np.abs(factor * pas)) < 1e-8:  # convergență
            break

    L, p, w, informatie = verosimilitate_penalizata(X, y, beta)
    erori_standard = np.sqrt(np.diag(np.linalg.inv(informatie)))
    return beta, erori_standard, L


# ---------------------------------------------------------------
# 9.5 Modelul complet: coeficienți și erori standard
# ---------------------------------------------------------------
coeficienti, erori_standard, L_complet = ajusteaza_firth(X, y)
print("coef", np.round(coeficienti, 4))
print("se", np.round(erori_standard, 4))

# ---------------------------------------------------------------
# 9.5 Chisq pe predictor: 2 * (L complet - L fără predictor)
# ---------------------------------------------------------------
# Modelul restrâns ține coeficientul j la 0 (j = 0 este interceptul, deci pornim de la 1).
for j, nume in enumerate(PREDICTORI, 1):
    _, _, L_restrans = ajusteaza_firth(X, y, coef_fixat=j)
    print(nume, "chisq", round(2 * (L_complet - L_restrans), 2))

# ---------------------------------------------------------------
# 9.5 Testele globale: au predictorii, împreună, vreun efect?
# ---------------------------------------------------------------
# Likelihood ratio: același calcul ca la Chisq, dar cu toți cei 5 coeficienți ținuți la 0
# (aceeași penalizare, deci rămâne doar interceptul).
_, _, L_doar_intercept = ajusteaza_firth(X, y, coef_fixat=list(range(1, X.shape[1])))
print("likelihood ratio", round(2 * (L_complet - L_doar_intercept), 1), "df", len(PREDICTORI))

# Wald: beta' * V^-1 * beta pe coeficienții predictorilor, cu V = matricea de covarianță (I^-1).
covarianta = np.linalg.inv(verosimilitate_penalizata(X, y, coeficienti)[3])[1:, 1:]
beta_predictori = coeficienti[1:]
print("wald", round(float(beta_predictori @ np.linalg.solve(covarianta, beta_predictori)), 1), "df", len(PRE
DICTORI))
```

05_cap8-9_cook_durbin_watson.py

```python
"""
Distanța Cook, reziduuri deviance, Durbin-Watson și verificarea câmpurilor „0”
(tema MQTTset, cap. 8 și 9).

Reproduce:
  - cap. 9.3: distanța Cook pentru regresia logistică atac/legitim
    (maximul, câte puncte trec de pragurile 4/n și 0,5) și reziduurile deviance;
  - cap. 8:   testul Durbin-Watson pentru cele două regresii liniare;
  - verificarea că valorile „0” din câmpurile MQTT înseamnă „câmp lipsă”
    (pachete fără MQTT), nu valoarea zero.

Intrare:  CSV-ul MQTTset și calea fișierului .npy de ieșire.
Ieșire:   text la consolă + fișierul .npy cu distanța Cook pentru fiecare pachet
          (folosit de 08_grafice_restul.py).

Rulare:
    python 05_cap8-9_cook_durbin_watson.py ../mqttdataset_reduced.csv.zip cook.npy
"""
import sys

import numpy as np
import pandas as pd
import statsmodels.api as sm
from statsmodels.stats.stattools import durbin_watson

date = pd.read_csv(sys.argv[1], low_memory=False)
fisier_cook = sys.argv[2]

# ---------------------------------------------------------------
# 9.3 Distanța Cook pentru regresia logistică
# ---------------------------------------------------------------
y = (date.target != "legitimate").astype(int).values
X = sm.add_constant(date[["tcp.len", "tcp.time_delta", "mqtt.len"]]).values
model_logistic = sm.GLM(y, X, family=sm.families.Binomial()).fit()

# clip: p exact 0 sau 1 ar da împărțire la zero mai jos
p = np.clip(model_logistic.predict(), 1e-12, 1 - 1e-12)
w = p * (1 - p)

# levierul h = diagonala matricei hat W^(1/2) X (X'WX)^-1 X' W^(1/2)
informatie_inv = np.linalg.inv((X * w[:, None]).T @ X)
levier = w * np.einsum("ij,jk,ik->i", X, informatie_inv, X)

# Cook pentru GLM: D_i = r_i^2 * h_i / (k * (1 - h_i)^2), cu r_i reziduul Pearson
reziduu_pearson = (y - p) / np.sqrt(w)
k = X.shape[1]  # numărul de parametri (cu intercept)
cook = reziduu_pearson**2 * levier / (k * (1 - levier) ** 2)

# Praguri uzuale: 4/n (regulă practică, depinde de mărimea setului) și 0,5 (influență mare)
n = len(y)
prag_4_n = 4 / n
print("cook max", cook.max(),
      "argmax row", cook.argmax() + 1,
      "n>4/n", (cook > prag_4_n).sum(), (cook > prag_4_n).mean(),
      "n>0.5", (cook > 0.5).sum(),
      "4/n", prag_4_n)

reziduu_deviance = model_logistic.resid_deviance
print("reziduuri deviance: max", np.abs(reziduu_deviance).max(),
      ">2", (np.abs(reziduu_deviance) > 2).sum(),
      ">3", (np.abs(reziduu_deviance) > 3).sum())

print("top5", np.sort(cook)[-5:])
np.save(fisier_cook, cook)

# ---------------------------------------------------------------
# Cap. 8 Durbin-Watson pentru cele două regresii liniare
# ---------------------------------------------------------------
# Regresia 1: mqtt.len ~ tcp.len; regresia 2: tcp.time_delta ~ tcp.len + mqtt.len
regresia1 = sm.OLS(date["mqtt.len"], sm.add_constant(date["tcp.len"])).fit()
regresia2 = sm.OLS(date["tcp.time_delta"], sm.add_constant(date[["tcp.len", "mqtt.len"]])).fit()
```

```
print("DW1", durbin_watson(regresia1.resid), "DW2", durbin_watson(regresia2.resid))

# ------------------------------------------------------------
# Verificarea câmpurilor „0”: apar doar la pachetele fără MQTT (msgtype 0)?
# ------------------------------------------------------------
# astype(str) separă „0” (câmp lipsă) de „0x00000000” (valoare reală)
print(pd.crosstab(date["mqtt.conack.flags"].astype(str), date["mqtt.msgtype"]))
print(pd.crosstab(date["mqtt.protoname"].astype(str), date["mqtt.msgtype"]))

fara_mqtt = date[date["mqtt.msgtype"] == 0]
print("msgtype0: hdrflags", fara_mqtt["mqtt.hdrflags"].astype(str).unique()[:5],
      "mqtt.len max", fara_mqtt["mqtt.len"].max())

print(pd.crosstab(date["mqtt.kalive"], date.target))
```

06_cap11_reguli_asociere.py

```python
"""
Reguli de asociere cu Apriori (tema MQTTset, cap. 11).

Reproduce:
  - tranzacțiile (fiecare pachet devine un set de itemi „atribut=valoare”);
  - itemseturile frecvente (support minim 5%) și cele 308 reguli după eliminarea
    regulilor redundante;
  - regulile care prezic fiecare tip de atac (support minim 300 / 150 pachete)
    și primele 3 reguli pe atac.

Intrare:  CSV-ul MQTTset; opțional, calea unui CSV de ieșire.
Ieșire:   text la consolă; dacă e dat al doilea argument, scrie în el regulile
          pe atacuri (folosit de graficul interactiv de pe site).

Rulare:
    python 06_cap11_reguli_asociere.py ../mqttdataset_reduced.csv.zip [reguli_atacuri.csv]

Notă: ordinea în care se afișează elementele unui frozenset depinde de
PYTHONHASHSEED; pentru o ieșire identică între rulări folosiți PYTHONHASHSEED=0.
"""
import sys

import pandas as pd
from mlxtend.frequent_patterns import apriori, association_rules

date = pd.read_csv(sys.argv[1], low_memory=False)

# ---------------------------------------------------------------
# 11.1 Tranzacțiile: discretizarea atributelor
# ---------------------------------------------------------------
FLAGURI_TCP = {
    "0x00000010": "ACK",
    "0x00000018": "PSH+ACK",
    "0x00000011": "FIN+ACK",
    "0x00000002": "SYN",
    "0x00000012": "SYN+ACK",
    "0x00000004": "RST",
    "0x00000019": "FIN+PSH+ACK",
    "0x00000014": "RST+ACK",
}
TIPURI_MESAJ_MQTT = {
    0: "fara",  # pachet TCP fără MQTT
    1: "CONNECT",
    2: "CONNACK",
    3: "PUBLISH",
    4: "PUBACK",
    5: "PUBREC",
    8: "SUBSCRIBE",
    9: "SUBACK",
    12: "PINGREQ",
    13: "PINGRESP",
    14: "DISCONNECT",
}

tranzactii = pd.DataFrame({
    "flags": date["tcp.flags"].map(FLAGURI_TCP),
    "msgtype": date["mqtt.msgtype"].astype(int).map(TIPURI_MESAJ_MQTT),
    "qos": date["mqtt.qos"].astype(int),
    "dupflag": date["mqtt.dupflag"].astype(int),
    # lungimea TCP: 0 = fără date, 1460 = MSS-ul obișnuit pe Ethernet
    "len": pd.cut(date["tcp.len"], [-1, 0, 20, 1460, 1e9],
                  labels=["0", "1-20", "21-1460", "1461+"]),
    # tcp.time_delta pe sferturi: limitele sunt cuartilele (Q1 iese 33% din cauza valorilor egale)
    "delta": pd.cut(date["tcp.time_delta"], [-1, 3e-6, 2.6e-5, 1.7e-4, 1e9],
                    labels=["Q1", "Q2", "Q3", "Q4"]),
    "target": date.target,
})
print(tranzactii.head(5).to_string())
print(tranzactii.delta.value_counts(normalize=True).round(3).to_dict())

# matricea one-hot: o coloană booleană pentru fiecare item „atribut=valoare”
```

```
itemi = pd.get_dummies(tranzactii.astype(str), prefix_sep="=")
print("items", itemi.shape[1])


# ---------------------------------------------------------------
# Funcții ajutătoare
# ---------------------------------------------------------------
def singurul_item(itemset):
    """Elementul unui frozenset cu un singur item (partea dreaptă a regulii)."""
    return next(iter(itemset))


def reguli_cu_un_item_in_dreapta(itemseturi, confidenta_minima):
    # Păstrăm doar reguli cu un singur item în dreapta, ca fiecare regulă să se citească
    # „aceste valori → o valoare” (decizia din 11.2).
    reguli = association_rules(itemseturi, metric="confidence", min_threshold=confidenta_minima)
    return reguli[reguli.consequents.apply(len) == 1]


def elimina_redundante(reguli):
    """Elimină regulile redundante.

    O regulă A => c e redundantă dacă există o regulă mai generală B => c
    (B submulțime strictă a lui A) cu confidența cel puțin la fel de mare:
    itemii în plus din A nu aduc nimic.
    """
    pastreaza = []
    for _, regula in reguli.iterrows():
        mai_generale = reguli[(reguli.consequents == regula.consequents)
                              & (reguli.antecedents.apply(lambda x: x < regula.antecedents))]
        pastreaza.append(len(mai_generale) == 0 or regula.confidence > mai_generale.confidence.max())
    return reguli[pastreaza]


# ---------------------------------------------------------------
# 11.2 Apriori pe tot setul: support >= 5%, confidență >= 0,6
# ---------------------------------------------------------------
frecvente = apriori(itemi, min_support=0.05, use_colnames=True)
frecvente["k"] = frecvente.itemsets.apply(len)
print("frequent per k", frecvente.k.value_counts().sort_index().to_dict())

reguli = reguli_cu_un_item_in_dreapta(frecvente, 0.6)
print("rules", len(reguli))

# n = numărul total de itemi din regulă (stânga + cel din dreapta)
reguli_finale = elimina_redundante(reguli)
reguli_finale = reguli_finale.assign(n=reguli_finale.antecedents.apply(len) + 1)
print("pruned", len(reguli_finale),
      reguli_finale.n.value_counts().sort_index().to_dict(),
      reguli_finale.support.min(), reguli_finale.support.max(),
      reguli_finale.lift.min(), reguli_finale.lift.max(), reguli_finale.lift.median())

cu_clasa_in_dreapta = reguli_finale[reguli_finale.consequents.apply(lambda x: singurul_item(x).startswith("t
arget"))]
print("RHS classes", cu_clasa_in_dreapta.consequents.apply(singurul_item).value_counts().to_dict())

top10_lift = reguli_finale.sort_values("lift", ascending=False).head(10)
print(top10_lift[["antecedents", "consequents", "support", "confidence", "lift"]].to_string())

# ---------------------------------------------------------------
# 11.3 Reguli pe atacuri
# ---------------------------------------------------------------
# Atacurile rare (ex. flood) nu ating 5%, deci pragul de support se dă
# în număr absolut de pachete (300, apoi 150).
ATACURI = ["target=" + atac for atac in ["dos", "bruteforce", "malformed", "slowite", "flood"]]

for pachete_minime in [300, 150]:
    frecvente_atac = apriori(itemi, min_support=pachete_minime / len(itemi), use_colnames=True, max_len=7)
    reguli_atac = reguli_cu_un_item_in_dreapta(frecvente_atac, 0.5)
    # dreapta = un atac, stânga = doar atribute ale pachetului (fără clasă)
    reguli_atac = reguli_atac[
        reguli_atac.consequents.apply(lambda x: singurul_item(x) in ATACURI)
        & reguli_atac.antecedents.apply(lambda x: not any(item.startswith("target") for item in x))
    ]
```

```
    reguli_atac = elimina_redundante(reguli_atac)
    print(pachete_minime, reguli_atac.consequents.apply(singurul_item).value_counts().to_dict())

# De aici se folosesc regulile de la ultimul prag (150 de pachete).
if len(sys.argv) > 2:
    pd.DataFrame({
        "stanga": reguli_atac.antecedents.apply(lambda x: " & ".join(sorted(x))),
        "atac": reguli_atac.consequents.apply(lambda x: singurul_item(x)[len("target="):]),
        "pachete": (reguli_atac.support * len(itemi)).round().astype(int),
        "support": reguli_atac.support,
        "confidence": reguli_atac.confidence,
        "lift": reguli_atac.lift,
    }).to_csv(sys.argv[2], index=False)

# primele 3 reguli pe atac (după confidență, apoi support)
for atac in ATACURI:
    reguli_atacului = reguli_atac[reguli_atac.consequents.apply(lambda x: singurul_item(x) == atac)]
    primele3 = reguli_atacului.sort_values(["confidence", "support"], ascending=False).head(3)
    for _, regula in primele3.iterrows():
        print(atac, sorted(regula.antecedents),
              round(regula.support * len(itemi)),
              round(regula.support, 4),
              round(regula.confidence, 3),
              round(regula.lift, 1))
```

07_grafice_corelatie.py

```python
"""
Graficele de corelație (tema MQTTset, cap. 7.1-7.3).

Reproduce:
  - corr_tot.png: harta corelațiilor Spearman pe tot setul;
  - corr_<clasă>.png: aceeași hartă pe fiecare clasă
    (corr_legitimate.png, corr_dos.png, ..., corr_flood.png);
  - corr_scatter.png: trei diagrame de dispersie pe ranguri, cu dreapta de regresie
    și R Spearman; la consolă se afișează R și p pentru fiecare pereche.

Intrare:  CSV-ul MQTTset și folderul de ieșire (trebuie să existe).
Ieșire:   fișierele PNG de mai sus + text la consolă.

Rulare:
    python 07_grafice_corelatie.py ../mqttdataset_reduced.csv.zip grafice
"""
import sys

import matplotlib
import numpy as np
import pandas as pd

matplotlib.use("Agg")  # fără fereastră, doar salvare în fișiere
import matplotlib.pyplot as plt
from matplotlib.ticker import FuncFormatter
from scipy import stats

date = pd.read_csv(sys.argv[1], low_memory=False)
folder_iesire = sys.argv[2]

VARIABILE = [
    "tcp.time_delta", "tcp.len", "mqtt.len", "mqtt.kalive", "mqtt.qos",
    "mqtt.dupflag", "mqtt.retain", "mqtt.conflag.cleansess", "mqtt.conflag.passwd",
    "mqtt.conflag.uname", "mqtt.proto_len", "mqtt.ver", "mqtt.conack.val",
]


def format_ro(valoare, zecimale=2):
    """Număr în format românesc: virgulă zecimală, minus tipografic, fără „-0,00”."""
    if round(valoare, zecimale) == 0:
        valoare = 0.0
    return f"{valoare:.{zecimale}f}".replace(".", ",").replace("-", "−")


# celulele NaN (corelație imposibilă) apar gri
paleta = plt.get_cmap("RdBu").copy()
paleta.set_bad("#dddddd")


def harta_corelatie(subset, titlu, nume_fisier):
    """Harta corelațiilor Spearman dintre VARIABILE, cu valoarea scrisă în fiecare celulă."""
    # o variabilă constantă în subset dă NaN (nu are ranguri diferite)
    corelatii = subset[VARIABILE].corr("spearman").values
    fig, ax = plt.subplots(figsize=(11.7, 9.88), dpi=100)
    imagine = ax.imshow(np.ma.masked_invalid(corelatii), cmap=paleta, vmin=-1, vmax=1)

    for i in range(len(VARIABILE)):
        for j in range(len(VARIABILE)):
            if not np.isnan(corelatii[i, j]):
                # text alb pe celulele închise la culoare, negru în rest
                culoare_text = "white" if abs(corelatii[i, j]) > 0.5 else "black"
                ax.text(j, i, format_ro(corelatii[i, j]),
                        ha="center", va="center", fontsize=7.5, color=culoare_text)

    ax.set_xticks(range(len(VARIABILE)))
    ax.set_xticklabels(VARIABILE, rotation=90, fontsize=9)
    ax.set_yticks(range(len(VARIABILE)))
    ax.set_yticklabels(VARIABILE, fontsize=9)
    bara_culori = fig.colorbar(imagine, ax=ax, shrink=0.8)
    bara_culori.ax.yaxis.set_major_formatter(FuncFormatter(lambda v, _: format_ro(v)))
    ax.set_title(titlu, fontsize=10)
```

```
    fig.tight_layout()
    fig.savefig(f"{folder_iesire}/{nume_fisier}")
    plt.close(fig)


# ---------------------------------------------------------------
# 7.1 Corelația Spearman pe tot setul (corr_tot.png)
# ---------------------------------------------------------------
harta_corelatie(date,
                "Corelația Spearman, variabile numerice, ordinale și binare, tot setul (gri = nu se poate ca
lcula)",
                "corr_tot.png")

# ---------------------------------------------------------------
# 7.3 Corelația Spearman pe fiecare clasă (corr_<clasă>.png)
# ---------------------------------------------------------------
CLASE = ["legitimate", "dos", "bruteforce", "malformed", "slowite", "flood"]
for clasa in CLASE:
    harta_corelatie(date[date.target == clasa],
                    f"Corelația Spearman, {clasa} (gri = variabilă constantă în această clasă)",
                    f"corr_{clasa}.png")

# ---------------------------------------------------------------
# 7.2 Diagrame de dispersie pe ranguri (corr_scatter.png)
# ---------------------------------------------------------------
# 8000 de pachete ajung pentru grafic; R și p se calculează pe tot setul.
esantion = date.sample(8000, random_state=42)
PERECHI = [("tcp.len", "mqtt.len"), ("tcp.time_delta", "tcp.len"), ("tcp.time_delta", "mqtt.len")]

fig, axe = plt.subplots(1, 3, figsize=(15.6, 4.94), dpi=100)
for ax, (var_x, var_y) in zip(axe, PERECHI):
    R, p = stats.spearmanr(date[var_x], date[var_y])

    # Spearman = Pearson pe ranguri, deci desenăm rangurile, nu valorile
    rang_x = esantion[var_x].rank()
    rang_y = esantion[var_y].rank()
    ax.scatter(rang_x, rang_y, s=4, c="black", alpha=0.3)

    panta, intercept = np.polyfit(rang_x, rang_y, 1)
    capete_x = np.array([rang_x.min(), rang_x.max()])
    ax.plot(capete_x, intercept + panta * capete_x, color="#3355aa")

    ax.set_xlabel(f"{var_x} (rang)")
    ax.set_ylabel(f"{var_y} (rang)")
    ax.set_title(f"R (Spearman) = {format_ro(R)}, p < 0,001", fontsize=10)
    print(var_x, var_y, R, p)

fig.tight_layout()
fig.savefig(f"{folder_iesire}/corr_scatter.png")
plt.close(fig)
```

08_grafice_restul.py

```python
"""
Graficele din raport care nu sunt produse de celelalte scripturi:
cap. 5 (distribuțiile variabilelor), cap. 6 (variabile pe clase),
7.4 (corelații Pearson / Spearman), cap. 8 (regresia liniară),
cap. 9 (distanța Cook, regresia logistică) și 11.4 (regulile de asociere).

Intrări:
  1. CSV-ul MQTTset redus (mqttdataset_reduced.csv)
  2. folderul în care se scriu imaginile
  3. fișierul .npy cu distanțele Cook, scris de 05_cap8-9_cook_durbin_watson.py

Ieșiri:
  imaginile PNG în folderul de ieșire, cu numele din document (desc_<variabilă>.png,
  test_<variabilă>.png, reg1_scatter.png, ...);
  la ecran: testele Mann-Whitney din cap. 6 și P(atac) la tcp.time_delta = 0.

Rulare:
  python 08_grafice_restul.py mqttdataset_reduced.csv folder_grafice cook.npy
"""
import sys

import matplotlib
import numpy as np
import pandas as pd
import statsmodels.api as sm

matplotlib.use("Agg")
import matplotlib.pyplot as plt
from matplotlib.ticker import FuncFormatter
from mlxtend.frequent_patterns import apriori, association_rules
from scipy import stats

date = pd.read_csv(sys.argv[1], low_memory=False)
folder_iesire = sys.argv[2]
distante_cook = np.load(sys.argv[3])

date["is_attack"] = (date.target != "legitimate").astype(int)
CLASE = ["legitimate", "dos", "bruteforce", "malformed", "slowite", "flood"]
ATACURI = CLASE[1:]


# ------------------------------------------------------------------------------
# Funcții ajutătoare: formatare românească (virgulă zecimală, minus tipografic)
# ------------------------------------------------------------------------------

def format_axa(valoare, _=None):
    """Eticheta unei gradații: 0.5 -> „0,5”, -1 -> „−1”."""
    text = ("%g" % valoare).replace(".", ",")
    return text.replace("-", "−")


def format_zecimale(valoare, zecimale):
    text = f"{valoare:.{zecimale}f}"
    return text.replace(".", ",").replace("-", "−")


def virgule_pe_axe(ax, si_pe_x=True):
    """Virgulă zecimală pe axele liniare. si_pe_x=False păstrează etichetele de categorii de pe x."""
    if si_pe_x and ax.get_xscale() == "linear":
        ax.xaxis.set_major_formatter(FuncFormatter(format_axa))
    if ax.get_yscale() == "linear":
        ax.yaxis.set_major_formatter(FuncFormatter(format_axa))


def eticheta_valoare(valoare):
    """3.0 -> „3”, 65535.0 -> „65.535”; valorile hex / text rămân neschimbate."""
    if isinstance(valoare, float) and valoare.is_integer():
        return f"{int(valoare):,}".replace(",", ".")
    return str(valoare)


```

```
 72 def salveaza(fig, nume_fisier, latime_px, inaltime_px):
 73     fig.set_size_inches(latime_px / 100, inaltime_px / 100)
 74     fig.savefig(f"{folder_iesire}/{nume_fisier}", dpi=100)
 75     plt.close(fig)
 76 
 77 
 78 def stele(p):
 79     if p < 0.001:
 80         return "***"
 81     if p < 0.01:
 82         return "**"
 83     if p < 0.05:
 84         return "*"
 85     return "ns"
 86 
 87 
 88 # ------------------------------------------------------------------------
 89 # Cap. 5: distribuția fiecărei variabile (bare cu % din pachete)
 90 # ------------------------------------------------------------------------
 91 
 92 FIGURI_CAP5 = [
 93     "mqtt.conack.flags", "mqtt.conack.val", "mqtt.conflag.cleansess", "mqtt.conflag.passwd", "mqtt.conflag.u
name", "mqtt.conflags", "mqtt.dupflag", "mqtt.hdrflags", "mqtt.msgtype", "mqtt.proto_len", "mqtt.protoname", "mq
tt.qos", "mqtt.retain", "mqtt.ver", "tcp.flags",
 94 ]
 95 
 96 
 97 def figura_distributie(coloana):
 98     procente = date[coloana].value_counts(normalize=True) * 100
 99     # peste 10 valori distincte: primele 10, restul adunate în „Altele”
100     if len(procente) > 10:
101         procente = pd.concat([procente.iloc[:10], pd.Series({"Altele": procente.iloc[10:].sum()})])
102     fig, ax = plt.subplots()
103     ax.bar([eticheta_valoare(v) for v in procente.index], procente.values)
104     ax.set_title(coloana)
105     ax.set_ylabel("% din pachete")
106     plt.setp(ax.get_xticklabels(), rotation=45, ha="right")
107     virgule_pe_axe(ax, si_pe_x=False)
108     fig.tight_layout()
109     salveaza(fig, f"desc_{coloana}.png", 600, 420)
110 
111 
112 for coloana in FIGURI_CAP5:
113     figura_distributie(coloana)
114 
115 
116 # ------------------------------------------------------------------------
117 # Cap. 6: fiecare variabilă pe clase (boxplot pentru numerice, bare pentru categorice)
118 # ------------------------------------------------------------------------
119 
120 FIGURI_CAP6 = [
121     "tcp.flags", "tcp.time_delta", "tcp.len", "mqtt.hdrflags", "mqtt.msgtype", "mqtt.dupflag", "mqtt.qos",
"mqtt.retain", "mqtt.len", "mqtt.conflags", "mqtt.conflag.cleansess", "mqtt.conflag.passwd", "mqtt.conflag.unam
e", "mqtt.kalive", "mqtt.protoname", "mqtt.proto_len", "mqtt.ver", "mqtt.conack.flags", "mqtt.conack.val",
122 ]
123 NUMERICE = ["tcp.time_delta", "tcp.len", "mqtt.len"]
124 # variabile ordinale desenate ca bare, dar testate cu Kruskal-Wallis / Mann-Whitney, nu chi-pătrat
125 ORDINALE_CU_BARE = ["mqtt.qos", "mqtt.kalive"]
126 legitime = date[date.target == "legitimate"]
127 
128 
129 def mann_whitney_atac_vs_normal(coloana):
130     """Stelele testului Mann-Whitney pentru fiecare atac comparat cu traficul normal."""
131     rezultat = {}
132     for atac in ATACURI:
133         normal = legitime[coloana].values
134         din_atac = date[date.target == atac][coloana].values
135         # o singură valoare în ambele grupuri: testul nu are sens
136         if np.unique(np.r_[normal, din_atac]).size == 1:
137             rezultat[atac] = "-"
138         else:
139             rezultat[atac] = stele(stats.mannwhitneyu(normal, din_atac).pvalue)
140     return rezultat
141 
```

```
142
143 def boxplot_pe_clase(ax, coloana):
144     valori = [date[date.target == clasa][coloana].values for clasa in CLASE]
145     if coloana == "tcp.time_delta":
146         # scara log nu poate afișa 0, așa că 0 este desenat ca 1e-6 s
147         valori = [np.where(v == 0, 1e-6, v) for v in valori]
148         ax.set_yscale("log")
149         nota = "; 0 afișat ca 1e-06 s"
150     else:
151         ax.set_yscale("symlog", linthresh=1)
152         nota = ""
153     ax.boxplot(valori, showfliers=False, widths=0.5)
154     ax.set_xticks(range(1, 7))
155     ax.set_xticklabels(CLASE)
156     sus = ax.get_ylim()[1]
157     teste = mann_whitney_atac_vs_normal(coloana)
158     for pozitie, atac in enumerate(ATACURI, 2):
159         ax.text(pozitie, sus, teste[atac], ha="center", va="bottom")
160     # loc deasupra cutiilor pentru stele (axele sunt logaritmice, deci înmulțim)
161     ax.set_ylim(top=sus * (30 if coloana == "tcp.time_delta" else 8))
162     ax.set_title(f"{coloana}  (Kruskal-Wallis ***; stele: atac vs normal{nota})", fontsize=9)
163     print(coloana, teste)
164
165
166 def bare_pe_clase(ax, coloana):
167     if date[coloana].dtype != object:
168         valori = date[coloana].map(eticheta_valoare)
169     else:
170         valori = date[coloana].astype(str)
171     # cele mai frecvente 6 valori, restul „Altele”
172     frecvente = valori.value_counts().index[:6]
173     valori = valori.where(valori.isin(frecvente), "Altele")
174     if coloana == "mqtt.kalive":
175         grupe_kalive = {0: "0", 60: "60", 65535: "65.535"}
176         valori = date[coloana].map(lambda v: grupe_kalive.get(v, "altele (1, 2, 3, 234)"))
177     procente = pd.crosstab(valori, date.target, normalize="columns")[CLASE] * 100
178     # ordinea în legendă: valorile scurte întâi, „Altele” la final
179     ordine = [v for v in sorted(procente.index, key=lambda v: (v.startswith(("Altele", "altele")), len(v),
v))]
180     procente = procente.loc[ordine]
181     numar_valori = len(procente)
182     latime_bara = 0.8 / numar_valori
183     for i, (valoare, rand) in enumerate(procente.iterrows()):
184         deplasare = (i - (numar_valori - 1) / 2) * latime_bara
185         ax.bar(np.arange(6) + deplasare, rand.values, latime_bara, label=valoare)
186     ax.set_xticks(range(6))
187     ax.set_xticklabels(CLASE)
188     ax.set_ylabel("% din clasă")
189     if coloana in ORDINALE_CU_BARE:
190         teste = mann_whitney_atac_vs_normal(coloana)
191         ax.set_ylim(0, 112)
192         for pozitie, atac in enumerate(ATACURI, 1):
193             ax.text(pozitie, 104, teste[atac], ha="center")
194         ax.set_title(f"{coloana}  (Kruskal-Wallis ***; stele: atac vs normal)", fontsize=9)
195         print(coloana, teste)
196     else:
197         ax.set_title(f"{coloana}  (chi-pătrat ***)", fontsize=9)
198     ax.legend(title="valoare", fontsize=7, title_fontsize=7, loc="upper left", bbox_to_anchor=(1.01, 1))
199
200
201 for coloana in FIGURI_CAP6:
202     fig, ax = plt.subplots()
203     if coloana in NUMERICE:
204         boxplot_pe_clase(ax, coloana)
205     else:
206         bare_pe_clase(ax, coloana)
207     plt.setp(ax.get_xticklabels(), rotation=30, ha="right")
208     virgule_pe_axe(ax, si_pe_x=False)
209     fig.set_size_inches(7.8, 5.04)
210     fig.tight_layout()
211     salveaza(fig, f"test_{coloana}.png", 780, 504)
212
213
214 # ----------------------------------------------------------------------------
```

```
# 7.4: matricile de corelație Pearson și Spearman (figura 48)
# ------------------------------------------------------------------------------

def figura_corelatii():
    variabile = ["tcp.len", "mqtt.len", "tcp.time_delta", "mqtt.qos", "mqtt.dupflag", "is_attack"]
    fig, axs = plt.subplots(1, 2, figsize=(12.53, 5.87))
    for ax, metoda in zip(axs, ["pearson", "spearman"]):
        corelatii = date[variabile].corr(metoda).values
        imagine = ax.imshow(corelatii, cmap="RdBu", vmin=-1, vmax=1)
        for i in range(6):
            for j in range(6):
                culoare_text = "white" if abs(corelatii[i, j]) > 0.5 else "black"
                ax.text(j, i, format_zecimale(corelatii[i, j], 2), ha="center", va="center",
                        fontsize=8, color=culoare_text)
        ax.set_xticks(range(6))
        ax.set_xticklabels(variabile, rotation=40, ha="right", fontsize=8)
        ax.set_yticks(range(6))
        # numele variabilelor doar pe matricea din stânga
        ax.set_yticklabels(variabile if metoda == "pearson" else [], fontsize=8)
        ax.set_title(metoda.capitalize())
    bara_culori = fig.colorbar(imagine, ax=axs, shrink=0.85)
    bara_culori.ax.yaxis.set_major_formatter(FuncFormatter(lambda v, _: format_zecimale(v, 2)))
    salveaza(fig, "corr_pearson_spearman.png", 1253, 587)


figura_corelatii()


# ------------------------------------------------------------------------------
# Cap. 8: regresia liniară (figurile 49-52)
# ------------------------------------------------------------------------------

# 8000 de pachete pentru norii de puncte; dreptele se calculează pe toate datele
esantion = date.sample(8000, random_state=42)

model_brut = sm.OLS(date["mqtt.len"], sm.add_constant(date["tcp.len"])).fit()
logaritmi = np.log1p(date[["tcp.len", "mqtt.len"]])
model_log = sm.OLS(logaritmi["mqtt.len"], sm.add_constant(logaritmi["tcp.len"])).fit()


def dreapta(ax, model, x_min, x_max):
    xx = np.array([x_min, x_max])
    ax.plot(xx, model.params.iloc[0] + model.params.iloc[1] * xx, "r")


def figura_mqtt_len_din_tcp_len():
    fig, axs = plt.subplots(1, 2)

    axs[0].scatter(esantion["tcp.len"], esantion["mqtt.len"], s=4, alpha=0.4)
    dreapta(axs[0], model_brut, 0, date["tcp.len"].max())
    axs[0].set_title(f"Valori brute, R² = {format_zecimale(model_brut.rsquared, 3)}")
    axs[0].set_xlabel("tcp.len")
    axs[0].set_ylabel("mqtt.len")

    esantion_log = np.log1p(esantion[["tcp.len", "mqtt.len"]])
    axs[1].scatter(esantion_log["tcp.len"], esantion_log["mqtt.len"], s=4, alpha=0.4)
    dreapta(axs[1], model_log, 0, logaritmi["tcp.len"].max())
    axs[1].set_title(f"După logaritm, R² = {format_zecimale(model_log.rsquared, 3)}")
    axs[1].set_xlabel("log(1 + tcp.len)")
    axs[1].set_ylabel("log(1 + mqtt.len)")

    for ax in axs:
        virgule_pe_axe(ax)
    fig.set_size_inches(14.3, 5.46)
    fig.tight_layout()
    salveaza(fig, "reg1_scatter.png", 1430, 546)


def reziduuri(ax_puncte, ax_histograma, prezise, reziduu, sufix_titlu=""):
    """Reziduuri față de predicție + histograma lor cu curba normală (media și abaterea reziduurilor)."""
    i = esantion.index
    ax_puncte.scatter(prezise[i], reziduu[i], s=4, alpha=0.4)
    ax_puncte.axhline(0, color="r")
    ax_puncte.set_title("Reziduuri față de predicție" + sufix_titlu)
```

```
    ax_puncte.set_xlabel("valoare prezisă")
    ax_puncte.set_ylabel("reziduu")

    # fără 1% din fiecare capăt, altfel câteva valori extreme strivesc histograma
    cuantile = reziduu.quantile([.01, .99])
    centrale = reziduu[(reziduu >= cuantile.iloc[0]) & (reziduu <= cuantile.iloc[1])]
    _, margini, _ = ax_histograma.hist(centrale, bins=50)
    xs = np.linspace(margini[0], margini[-1], 300)
    latime_bin = margini[1] - margini[0]
    curba = len(centrale) * latime_bin * stats.norm.pdf(xs, centrale.mean(), centrale.std())
    ax_histograma.plot(xs, curba, "r", lw=2, label="curba normală")
    ax_histograma.set_title("Histograma reziduurilor, 1% până la 99%" + sufix_titlu)
    ax_histograma.set_xlabel("reziduu")
    ax_histograma.legend(frameon=False)
    virgule_pe_axe(ax_puncte)
    virgule_pe_axe(ax_histograma)


def figura_reziduuri_mqtt_len():
    fig, axs = plt.subplots(2, 2)
    reziduuri(*axs[0], model_brut.fittedvalues, model_brut.resid, " (brute)")
    reziduuri(*axs[1], model_log.fittedvalues, model_log.resid, " (logaritm)")
    fig.set_size_inches(14.3, 9.1)
    fig.tight_layout()
    salveaza(fig, "reg1_reziduuri.png", 1430, 910)


def figura_reziduuri_time_delta():
    model_timp = sm.OLS(date["tcp.time_delta"], sm.add_constant(date[["tcp.len", "mqtt.len"]])).fit()
    fig, axs = plt.subplots(1, 2)
    reziduuri(*axs, model_timp.fittedvalues, model_timp.resid)
    fig.set_size_inches(14.3, 5.46)
    fig.tight_layout()
    salveaza(fig, "reg2_reziduuri.png", 1430, 546)


def figura_regresie_pe_clase():
    fig, axs = plt.subplots(2, 3)
    for ax, clasa in zip(axs.flat, CLASE):
        din_clasa = date[date.target == clasa]
        model = sm.OLS(din_clasa["mqtt.len"], sm.add_constant(din_clasa["tcp.len"])).fit()
        puncte = din_clasa if len(din_clasa) < 3000 else din_clasa.sample(3000, random_state=42)
        ax.scatter(puncte["tcp.len"], puncte["mqtt.len"], s=4, alpha=0.4)
        dreapta(ax, model, din_clasa["tcp.len"].min(), din_clasa["tcp.len"].max())
        panta = format_zecimale(model.params.iloc[1], 3)
        ax.set_title(f"{clasa}: panta {panta}, R² = {format_zecimale(model.rsquared, 3)}", fontsize=9)
        ax.set_xlabel("tcp.len", fontsize=8)
        ax.set_ylabel("mqtt.len", fontsize=8)
        ax.tick_params(labelsize=7)
        virgule_pe_axe(ax)
    fig.set_size_inches(16.9, 9.1)
    fig.tight_layout()
    salveaza(fig, "reg3_pe_clase.png", 1690, 910)


figura_mqtt_len_din_tcp_len()
figura_reziduuri_mqtt_len()
figura_reziduuri_time_delta()
figura_regresie_pe_clase()


# ---------------------------------------------------------------------------
# Cap. 9: distanța Cook, curba P(atac) și probabilitățile prezise (figurile 53, 56, 57)
# ---------------------------------------------------------------------------

def figura_cook():
    n = len(distante_cook)
    fig, ax = plt.subplots()
    ax.vlines(np.arange(1, n + 1), 0, distante_cook, lw=0.5, alpha=0.6)
    # 4/n este pragul uzual pentru „influent”; 0,5 sau 1 sunt pragurile critice
    ax.axhline(4 / n, color="r", ls="--", lw=0.8, label=f"4/n = {format_zecimale(4 / n * 1e5, 1)} · 10⁻⁵")
    ax.set_title("Distanța Cook, modelul fără separare (maxim " + format_zecimale(distante_cook.max(), 4)
                 + ", pragul critic 0,5 sau 1)", fontsize=10)
    ax.set_xlabel("numărul pachetului (rândul din fișier)")
```

```
    ax.set_ylabel("distanța Cook")
    ax.legend(fontsize=8)
    virgule_pe_axe(ax)
    ax.xaxis.set_major_formatter(FuncFormatter(lambda v, _: f"{int(v):,}".replace(",", ".")))
    fig.set_size_inches(13, 5.2)
    fig.tight_layout()
    salveaza(fig, "cook.png", 1300, 520)


# modelul logistic final: is_attack ~ tcp.len + tcp.time_delta + mqtt.len
model_logistic = sm.GLM(date.is_attack, sm.add_constant(date[["tcp.len", "tcp.time_delta", "mqtt.len"]]),
                        family=sm.families.Binomial()).fit()


def figura_curba_probabilitate():
    coef = model_logistic.params
    timp = np.linspace(0, 2, 200)
    # tcp.len și mqtt.len fixate la valorile tipice (12 și 10)
    logit = coef.iloc[0] + coef["tcp.len"] * 12 + coef["tcp.time_delta"] * timp + coef["mqtt.len"] * 10
    probabilitate = 1 / (1 + np.exp(-logit))
    fig, ax = plt.subplots()
    ax.plot(timp, probabilitate, color="#d62728", lw=2)
    ax.axhline(0.5, color="gray", ls=":")
    ax.set_ylim(0, 1)
    ax.set_title("Probabilitatea de atac prezisă de modelul final\n"
                 "(tcp.len = 12 și mqtt.len = 10, valorile tipice; doar timpul variază)", fontsize=10)
    ax.set_xlabel("tcp.time_delta (secunde)")
    ax.set_ylabel("P(atac)")
    virgule_pe_axe(ax)
    fig.set_size_inches(10.5, 4.8)
    fig.tight_layout()
    salveaza(fig, "log_curba.png", 1050, 480)
    print("curve p0", probabilitate[0])


def figura_probabilitati_prezise():
    prezise = model_logistic.predict()
    fig, ax = plt.subplots()
    intervale = np.linspace(0, 1, 51)
    ax.hist(prezise[date.is_attack == 0], bins=intervale, alpha=0.6, label="normal (0)")
    ax.hist(prezise[date.is_attack == 1], bins=intervale, alpha=0.6, color="#e15759", label="atac (1)")
    ax.set_yscale("log")
    ax.set_xlabel("probabilitatea de atac prezisă")
    ax.set_ylabel("pachete (scară log)")
    ax.set_title("Ce scoate modelul final pentru fiecare pachet, separat pe grupul real", fontsize=10)
    ax.legend()
    virgule_pe_axe(ax)
    fig.set_size_inches(10.5, 4.8)
    fig.tight_layout()
    salveaza(fig, "log_prob.png", 1050, 480)


figura_cook()
figura_curba_probabilitate()
figura_probabilitati_prezise()


# ---------------------------------------------------------------------------
# 11.4: regulile de asociere, support față de confidence (figura 64)
# ---------------------------------------------------------------------------

NUME_FLAGURI_TCP = {
    "0x00000010": "ACK", "0x00000018": "PSH+ACK", "0x00000011": "FIN+ACK", "0x00000002": "SYN",
    "0x00000012": "SYN+ACK", "0x00000004": "RST", "0x00000019": "FIN+PSH+ACK", "0x00000014": "RST+ACK",
}
NUME_MESAJE_MQTT = {
    0: "fara", 1: "CONNECT", 2: "CONNACK", 3: "PUBLISH", 4: "PUBACK", 5: "PUBREC",
    8: "SUBSCRIBE", 9: "SUBACK", 12: "PINGREQ", 13: "PINGRESP", 14: "DISCONNECT",
}
CULORI_ATACURI = {"dos": "#e8692f", "bruteforce": "#1aae80", "malformed": "#f0a30a",
                  "slowite": "#e377a6", "flood": "#008000"}

# fiecare pachet devine o tranzacție; variabilele continue sunt împărțite în intervale
tranzactii = pd.DataFrame({
```

```
    "flags": date["tcp.flags"].map(NUME_FLAGURI_TCP),
    "msgtype": date["mqtt.msgtype"].astype(int).map(NUME_MESAJE_MQTT),
    "qos": date["mqtt.qos"].astype(int),
    "dupflag": date["mqtt.dupflag"].astype(int),
    "len": pd.cut(date["tcp.len"], [-1, 0, 20, 1460, 1e9], labels=["0", "1-20", "21-1460", "1461+"]),
    "delta": pd.cut(date["tcp.time_delta"], [-1, 3e-6, 2.6e-5, 1.7e-4, 1e9], labels=["Q1", "Q2", "Q3", "Q
4"]),
    "target": date.target,
})
itemi = pd.get_dummies(tranzactii.astype(str), prefix_sep="=")


def elimina_redundante(reguli):
    """Păstrează o regulă doar dacă are confidence mai mare decât orice regulă mai scurtă cu aceeași concluz
ie."""
    pastreaza = []
    for _, regula in reguli.iterrows():
        mai_scurte = reguli[(reguli.consequents == regula.consequents)
                            & (reguli.antecedents.apply(lambda x: x < regula.antecedents))]
        pastreaza.append(len(mai_scurte) == 0 or regula.confidence > mai_scurte.confidence.max())
    return reguli[pastreaza]


def concluzia(itemset):
    return next(iter(itemset))


# rularea generală: support ≥ 5%, confidence ≥ 60%, o singură concluzie
reguli_generale = association_rules(apriori(itemi, min_support=0.05, use_colnames=True),
                                    metric="confidence", min_threshold=0.6)
reguli_generale = elimina_redundante(reguli_generale[reguli_generale.consequents.apply(len) == 1])

# rularea pe atacuri: support de doar 150 de pachete (atacurile rare), concluzia este un atac,
# iar premisele nu conțin clasa
reguli_atacuri = association_rules(apriori(itemi, min_support=150 / len(itemi), use_colnames=True),
                                   metric="confidence", min_threshold=0.5)
reguli_atacuri = reguli_atacuri[reguli_atacuri.consequents.apply(len) == 1]
concluzii_atac = ["target=" + atac for atac in ATACURI]
concluzie_e_atac = reguli_atacuri.consequents.apply(lambda x: concluzia(x) in concluzii_atac)
premise_fara_clasa = reguli_atacuri.antecedents.apply(lambda x: not any(i.startswith("target") for i in x))
reguli_atacuri = elimina_redundante(reguli_atacuri[concluzie_e_atac & premise_fara_clasa])


def figura_reguli():
    fig, axs = plt.subplots(1, 2)

    puncte = axs[0].scatter(reguli_generale.support, reguli_generale.confidence, c=reguli_generale.lift,
                            cmap="Blues", s=14, edgecolors="gray", linewidths=0.3)
    bara_culori = fig.colorbar(puncte, ax=axs[0])
    bara_culori.set_label("lift")
    bara_culori.ax.yaxis.set_major_formatter(FuncFormatter(format_axa))
    axs[0].set_title(f"Rularea generală ({len(reguli_generale)} reguli)")
    axs[0].set_xlabel("support")
    axs[0].set_ylabel("confidence")

    for atac in ATACURI:
        ale_atacului = reguli_atacuri[reguli_atacuri.consequents.apply(lambda x: concluzia(x) == "target=" +
atac)]
        axs[1].scatter(ale_atacului.support, ale_atacului.confidence, s=14, color=CULORI_ATACURI[atac], labe
l=atac)
    axs[1].set_xscale("log")
    axs[1].set_title(f"Reguli pe atacuri ({len(reguli_atacuri)} reguli)")
    axs[1].set_xlabel("support (scară logaritmică)")
    axs[1].set_ylabel("confidence")
    axs[1].legend(fontsize=8)

    for ax in axs:
        virgule_pe_axe(ax)
    fig.set_size_inches(18, 7.6)
    fig.tight_layout()
    salveaza(fig, "ar_scatter.png", 1800, 760)


figura_reguli()
```

09_cap10_arbori_ctree.R

```r
# ============================================================================
# Cap. 10: arborii de decizie cu partykit::ctree
#
# Reproduce cifrele din cap. 10: alegerea adâncimii (10.3), tabelul testelor
# din rădăcină (10.1), arborele de clasificare și frunzele lui (10.4),
# metricile (10.5), verificările din 10.2 / 10.4 și arborele de
# regresie pentru tcp.len (10.6).
#
# ctree alege la fiecare nod variabila cu cel mai mic p al unui test de
# independență și desparte nodul doar dacă acest p, corectat Bonferroni,
# este sub 0,05. Așa arborele se oprește singur, fără tăiere ulterioară.
#
# Arborii se construiesc pe toate cele 330.926 de pachete, iar metricile se
# calculează pe aceleași pachete (fără împărțire în construcție și test).
#
# Intrări:
#   1. arhiva zip cu mqttdataset_reduced.csv
#   2. (opțional) folderul de ieșire pentru CSV-uri
# Ieșiri:
#   la ecran: toate rezultatele;
#   în folder: adancime_clasificare.csv, adancime_regresie.csv (10.3) și
#   noduri_clasificare.csv, noduri_regresie.csv (pentru 10_grafice_arbori.py).
#
# Rulare (durează câteva minute; are nevoie de r-base și r-cran-partykit):
#   Rscript 09_cap10_arbori_ctree.R ../mqttdataset_reduced.csv.zip folder_grafice
# ============================================================================

suppressMessages(library(partykit))
argumente <- commandArgs(TRUE)


# ---- Citirea datelor ---------------------------------------------------------

# Coloanele hex se citesc ca text: altfel R le transformă în numere,
# iar „0” și „0x00000000” ar deveni aceeași valoare.
d <- read.csv(unz(argumente[1], "mqttdataset_reduced.csv"), check.names = FALSE,
              colClasses = c(tcp.flags = "character", mqtt.conack.flags = "character",
                             mqtt.conflags = "character", mqtt.hdrflags = "character"))
names(d) <- make.names(names(d))

# Textul și codurile (tipul mesajului, dupflag, versiunea) sunt categorii, nu numere.
for (v in c(names(d)[sapply(d, is.character)], "mqtt.msgtype", "mqtt.dupflag", "mqtt.ver")) {
  d[[v]] <- factor(d[[v]])
}
options(digits = 10)  # pragurile din print, nerotunjite
d$is_attack <- factor(ifelse(d$target == "legitimate", "normal", "atac"), c("normal", "atac"))
cat("pachete", nrow(d), "\n")
print(table(d$is_attack))


# ---- Setările arborilor și metricile -----------------------------------------

# quadratic + Bonferroni: testul chi-pătrat al fiecărei variabile, cu p înmulțit
#   cu numărul de variabile testate (altfel, cu 7 variabile, una ar ieși
#   „semnificativă” din întâmplare mult mai des de 5% din cazuri);
# mincriterion 0,95: se desparte doar dacă 1 - p ajustat > 0,95;
# minbucket 300: fiecare frunză are măcar 300 de pachete, ca să nu apară
#   frunze pentru câteva pachete izolate (cu 330.926 de rânduri, aproape orice
#   despărțire ar fi „semnificativă”).
setari <- function(maxdepth, testtype = "Bonferroni") {
  ctree_control(teststat = "quadratic", testtype = testtype, mincriterion = 0.95,
                minsplit = 20, minbucket = 300, maxdepth = maxdepth)
}
X7 <- c("tcp.flags", "mqtt.msgtype", "tcp.len", "tcp.time_delta", "mqtt.qos", "mqtt.dupflag", "mqtt.ver")
formula_clasificare <- reformulate(X7, "is_attack")
formula_regresie <- tcp.len ~ target + tcp.flags + mqtt.msgtype + tcp.time_delta

# acuratețe, sensibilitate, precizie, F1; clasa pozitivă este „atac”
metrici_clasificare <- function(real, prezis) {
  tp <- sum(prezis == "atac" & real == "atac")
  fp <- sum(prezis == "atac" & real == "normal")
```

```r
  fn <- sum(prezis == "normal" & real == "atac")
  sensibilitate <- tp / (tp + fn)
  precizie <- tp / (tp + fp)
  round(c(acc = mean(prezis == real), sens = sensibilitate, prec = precizie,
          f1 = 2 * sensibilitate * precizie / (sensibilitate + precizie)), 4)
}
metrici_regresie <- function(real, prezis) {
  round(c(MAE = mean(abs(real - prezis)), RMSE = sqrt(mean((real - prezis)^2)),
          R2 = 1 - sum((real - prezis)^2) / sum((real - mean(real))^2)), 4)
}

folder_iesire <- if (is.na(argumente[2])) NULL else {
  dir.create(argumente[2], showWarnings = FALSE)
  argumente[2]
}
afiseaza_si_salveaza <- function(tabel, fisier) {
  print(tabel)
  if (!is.null(folder_iesire)) write.csv(tabel, file.path(folder_iesire, fisier), row.names = FALSE)
}


# ---- 10.3 Alegerea adâncimii maxime ----------------------------------------

cat("\n10.3 maxdepth, clasificare\n")
afiseaza_si_salveaza(do.call(rbind, lapply(2:6, function(md) {
  arbore <- ctree(formula_clasificare, d, control = setari(md))
  data.frame(maxdepth = md, frunze = width(arbore), t(metrici_clasificare(d$is_attack, predict(arbore))[c(1,
4)]))
})), "adancime_clasificare.csv")

cat("\n10.3 maxdepth, regresie\n")
afiseaza_si_salveaza(do.call(rbind, lapply(2:6, function(md) {
  arbore <- ctree(formula_regresie, d, control = setari(md))
  data.frame(maxdepth = md, frunze = width(arbore), t(metrici_regresie(d$tcp.len, predict(arbore))))
})), "adancime_regresie.csv")


# ---- 10.4 Arborele de clasificare (maxdepth 5) -----------------------------

m <- ctree(formula_clasificare, d, control = setari(5))
cat("\n10.4 arborele de clasificare\n")
print(m)
cat("aceleasi predictii la maxdepth 6:",
    identical(predict(m), predict(ctree(formula_clasificare, d, control = setari(6)))), "\n")


# ---- 10.1 Testele din rădăcină ---------------------------------------------

# Statistica fiecărei variabile în rădăcină, cu p recalculat din chi-pătrat;
# log10p7 = p înmulțit cu 7 (corecția Bonferroni pentru cele 7 variabile).
cat("\n10.1 radacina: statistica, df, log10 p, log10 p*7\n")
statistici <- info_node(node_party(m))$criterion["statistic", ]
grade_libertate <- sapply(X7, function(v) if (is.factor(d[[v]])) nlevels(droplevels(d[[v]])) - 1 else 1)
log10_p <- pchisq(statistici, grade_libertate, lower.tail = FALSE, log.p = TRUE) / log(10)
print(round(cbind(T = statistici, df = grade_libertate, log10p = log10_p, log10p7 = log10_p + log10(7))[orde
r(log10_p), ], 2))

# Verificare de mână pentru mqtt.qos: statistica este chi-pătrat pe tabelul 2x2
# (qos > 0 față de atac), adică (n - 1) * r².
q <- table(d$mqtt.qos > 0, d$is_attack)
E <- outer(rowSums(q), colSums(q)) / sum(q)
cat("tabel qos: O\n")
print(q)
cat("E\n")
print(round(E, 1))
cat("chi2", sum((q - E)^2 / E),
    " (n-1) r2", (nrow(d) - 1) * cor(d$mqtt.qos, as.numeric(d$is_attack))^2,
    " r", cor(d$mqtt.qos, as.numeric(d$is_attack)), "\n")

# Același arbore fără corecția Bonferroni
fara_bonferroni <- ctree(formula_clasificare, d, control = setari(5, "Univariate"))
cat("\nfara Bonferroni: frunze", width(fara_bonferroni),
    " aceleasi predictii:", identical(predict(fara_bonferroni), predict(m)), "\n")
# cel mai mare p ajustat dintr-o despărțire, cu numărul de predictori testați acolo
```

```r
for (id in nodeids(m)) {
  nod <- nodeapply(m, id, identity)[[1]]
  if (!is.null(split_node(nod))) {
    cr <- info_node(nod)$criterion
    cat("nod", id, "p ajustat", info_node(nod)$p.value, " p minim", min(exp(cr["p.value", ]), na.rm = TRUE),
        " predictori testati", sum(!is.na(cr["p.value", ])), "\n")
  }
}


# ---- 10.4 Frunzele arborelui de clasificare --------------------------------

cat("\nfrunze: id | regula | n | % atac | prezice | clase\n")
frunza <- predict(m, type = "node")
reguli <- partykit:::.list.rules.party(m)
for (id in sort(unique(frunza))) {
  in_frunza <- frunza == id
  clase <- sort(table(d$target[in_frunza]), decreasing = TRUE)
  clase <- clase[clase > 0]
  cat(id, "|", reguli[as.character(id)], "|", sum(in_frunza), "|",
      round(100 * mean(d$is_attack[in_frunza] == "atac"), 2), "|",
      as.character(predict(m, d[which(in_frunza)[1], ])), "|",
      paste(names(clase), clase, collapse = "; "), "\n")
}


# ---- 10.5 Evaluarea ---------------------------------------------------------

prezis <- predict(m)
cat("\n10.5 evaluare\n")
print(table(real = d$is_attack, prezis = prezis))
cat(metrici_clasificare(d$is_attack, prezis), "\n")
print(t(sapply(split(prezis != d$is_attack, d$target), function(x) c(n = length(x), gresite = sum(x)))))
ratate <- d$is_attack == "atac" & prezis == "normal"
cat("atacuri ratate pe frunze:\n")
print(table(frunza[ratate]))


# ---- Verificări 10.2 / 10.4 -------------------------------------------------

cat("\nverificari 10.2 / 10.4\n")
# Toate variabilele care nu sunt constante (fără clasă, conținutul mesajului și id-ul lui)
X19 <- setdiff(names(d)[sapply(d, function(x) length(unique(x)) > 1)],
               c("target", "is_attack", "mqtt.msg", "mqtt.msgid"))
m19 <- ctree(reformulate(X19, "is_attack"), d, control = setari(5))
cat(length(X19), "variabile: F1", metrici_clasificare(d$is_attack, predict(m19))[4],
    " radacina:", names(m19$data)[split_node(node_party(m19))$varid], "\n")

# tcp.len grupat în 3 intervale în loc de valoarea exactă
d$len3 <- cut(d$tcp.len, c(-1, 0, 20, Inf))
m_len3 <- ctree(reformulate(c(setdiff(X7, "tcp.len"), "len3"), "is_attack"), d, control = setari(5))
cat("tcp.len in 0 / 1-20 / 21+: F1", metrici_clasificare(d$is_attack, predict(m_len3))[4], "\n")


# ---- 10.6 Arborele de regresie pentru tcp.len (maxdepth 4) ------------------

r <- ctree(formula_regresie, d, control = setari(4))
cat("\n10.6 arborele de regresie\n")
print(r)
eroare <- d$tcp.len - predict(r)
cat(metrici_regresie(d$tcp.len, predict(r)), "\n")
cat("suma |e|", sum(abs(eroare)), " SSE", sum(eroare^2), " SST", sum((d$tcp.len - mean(d$tcp.len))^2), "\n")
cat("cota SSE pe clase:\n")
print(round(tapply(eroare^2, d$target, sum) / sum(eroare^2), 4))

frunza_reg <- predict(r, type = "node")
cat("frunze regresie: id | n | media | mediana | clase\n")
for (id in sort(unique(frunza_reg))) {
  in_frunza <- frunza_reg == id
  clase <- table(droplevels(d$target[in_frunza]))
  cat(id, "|", sum(in_frunza), "|", round(mean(d$tcp.len[in_frunza]), 1), "|",
      median(d$tcp.len[in_frunza]), "|", paste(names(clase), clase, collapse = "; "), "\n")
}

```

```r
cat("\ncomparatie cu regresia liniara (R2: dreapta, arbore)\n")
for (f in list(mqtt.len ~ tcp.len, tcp.time_delta ~ tcp.len + mqtt.len)) {
  real <- d[[all.vars(f)[1]]]
  cat(deparse(f), metrici_regresie(real, fitted(lm(f, d)))[3],
      metrici_regresie(real, predict(ctree(f, d, control = setari(4))))[3], "\n")
}


# ---- Tabelul nodurilor, pentru desene (10_grafice_arbori.py) ----------------

# Un rând pentru fiecare nod: id, copii (id-uri separate prin „;”), variabila
# despărțirii, p ajustat, etichetele ramurilor (separate prin „|”), n și
# conținutul nodului: numărul de pachete din fiecare clasă (clasificare) sau
# cuantilele și media lui tcp.len (regresie).
# Nodurile interne nu au rândurile lor în predict(type = "node"), așa că
# se adună frunzele de sub ele.
noduri <- function(arbore, y) {
  frunza <- predict(arbore, type = "node")
  do.call(rbind, lapply(nodeids(arbore), function(id) {
    nod <- nodeapply(arbore, id, identity)[[1]]  # id-urile din arborele întreg
    despartire <- split_node(nod)
    valori <- y[frunza %in% nodeids(arbore, id, terminal = TRUE)]
    rand <- data.frame(id = id, copii = "", var = "", p = NA, ramuri = "", n = length(valori))
    if (!is.null(despartire)) {
      rand$copii <- paste(sapply(kids_node(nod), id_node), collapse = ";")
      rand$var <- names(arbore$data)[despartire$varid]
      rand$p <- info_node(nod)$p.value
      rand$ramuri <- paste(character_split(despartire, arbore$data, digits = 6)$levels, collapse = "|")
    }
    continut <- if (is.factor(y)) t(as.matrix(table(valori))) else
      t(c(quantile(valori, c(0, .25, .5, .75, 1)), media = mean(valori)))
    cbind(rand, continut)
  }))
}
if (!is.null(folder_iesire)) {
  write.csv(noduri(m, d$target), file.path(folder_iesire, "noduri_clasificare.csv"), row.names = FALSE)
  write.csv(noduri(r, d$tcp.len), file.path(folder_iesire, "noduri_regresie.csv"), row.names = FALSE)
}
```

10_grafice_arbori.py

```
"""
Graficele din cap. 10 (arborii de decizie), desenate din CSV-urile scrise de
09_cap10_arbori_ctree.R.

Intrări (în folderul dat ca prim argument):
  noduri_clasificare.csv, noduri_regresie.csv  - tabelul nodurilor celor doi arbori
  adancime_clasificare.csv, adancime_regresie.csv  - metricile pe maxdepth 2-6 (10.3)

Ieșiri (în folderul dat ca al doilea argument):
  arbore_clasificare.png  - arborele is_attack; în fiecare frunză, bara cu clasele pachetelor
  arbore_regresie.png     - arborele tcp.len; în fiecare frunză, boxplot pe scară log
  adancime.png            - F1 / R² pe toate pachetele, în funcție de maxdepth

Rulare:
  python 10_grafice_arbori.py folder_csv folder_iesire
"""
import re
import sys
import textwrap

import matplotlib
import numpy as np
import pandas as pd

matplotlib.use("Agg")
import matplotlib.pyplot as plt
from matplotlib.lines import Line2D
from matplotlib.patches import Patch, Rectangle

folder_csv = sys.argv[1]
folder_iesire = sys.argv[2]

CULORI_CLASE = {"legitimate": "#2a7ad6", "dos": "#e8692f", "bruteforce": "#1aae80",
                "malformed": "#f0a30a", "slowite": "#e377a6", "flood": "#008000"}


def format_zecimale(valoare, zecimale):
    """Format românesc: 12345.6 -> „12.345,6”."""
    text = f"{valoare:,.{zecimale}f}"
    return text.replace(",", " ").replace(".", ",").replace(" ", ".")


def format_scurt(valoare):
    return ("%g" % valoare).replace(".", ",")


def eticheta_ramura(text):
    """Eticheta unei ramuri din R: „<= 1e-06” -> „≤ 1e-06”; „0x00000018” -> „0x18”; listă -> „∈ {...}”."""
    text = re.sub(r"0x0+([0-9a-f]{2})", r"0x\1", text)
    prag = re.match(r"(<=|>) (.+)", text)
    if prag:
        semn = "≤ " if prag[1] == "<=" else "> "
        return semn + format_scurt(float(prag[2]))
    valori = text.split(", ")
    if len(valori) == 1:
        return "= " + valori[0]
    return textwrap.fill("∈ {" + ", ".join(valori) + "}", 16)


# ---------------------------------------------------------------------------
# Desenul unui arbore: nodurile interne sus, toate frunzele pe ultimul rând
# ---------------------------------------------------------------------------

def deseneaza_arbore(fisier_csv, titlu, fisier_png, deseneaza_frunza, legenda):
    noduri = pd.read_csv(fisier_csv, keep_default_na=False).set_index("id")
    copii = {i: [int(k) for k in str(nod.copii).split(";")] if nod.copii else [] for i, nod in noduri.iterro
ws()}

    # poziții: frunzele la x = 0, 1, 2, ... în ordinea parcurgerii,
    # fiecare nod intern deasupra mijlocului copiilor lui; y = -adâncimea
    x, y, frunze = {}, {}, []
```

```
 71
 72      def pozitioneaza(nod, adancime):
 73          y[nod] = -adancime
 74          if not copii[nod]:
 75              x[nod] = len(frunze)
 76              frunze.append(nod)
 77          else:
 78              for copil in copii[nod]:
 79                  pozitioneaza(copil, adancime + 1)
 80              x[nod] = np.mean([x[copil] for copil in copii[nod]])
 81
 82      pozitioneaza(1, 0)
 83      y_frunze = min(y.values()) - 0.6
 84
 85      fig, ax = plt.subplots(figsize=(17, 12))
 86      for nod in noduri.index:  # liniile și etichetele ramurilor, apoi caseta nodului
 87          if not copii[nod]:
 88              continue
 89          rand = noduri.loc[nod]
 90          for copil, eticheta in zip(copii[nod], rand.ramuri.split("|")):
 91              este_frunza = not copii[copil]
 92              y_copil = y_frunze if este_frunza else y[copil]
 93              y_capat = y_copil + (0.45 if este_frunza else 0)
 94              ax.plot([x[nod], x[copil]], [y[nod], y_capat], color="#999", lw=1, zorder=1)
 95              # eticheta mai aproape de copil, ca să nu se suprapună cu a fratelui
 96              f = 0.8 if este_frunza else 0.55
 97              ax.text(x[nod] + f * (x[copil] - x[nod]), y[nod] + f * (y_capat - y[nod]), eticheta_ramura(etich
eta),
 98                      ha="center", va="center", fontsize=9, bbox=dict(fc="white", ec="none", pad=0.5), zorder=
2)
 99          p = float(rand.p)
100          text_p = "p < 0,001" if p < 0.001 else "p = " + format_zecimale(p, 3)
101          ax.text(x[nod], y[nod], f"{nod}  {rand['var']}\n" + text_p, ha="center", va="center",
102                  fontsize=10, bbox=dict(boxstyle="round", fc="#eef3fb", ec="#7f9fd4"), zorder=3)
103
104      for nod in frunze:
105          ax.text(x[nod], y_frunze + 0.2, str(nod), ha="center", fontsize=10)
106          deseneaza_frunza(ax, x[nod], y_frunze, noduri.loc[nod])
107
108      ax.set_xlim(-0.8, len(frunze) - 0.2)
109      ax.set_ylim(y_frunze - 2.4, 0.5)
110      ax.axis("off")
111      ax.set_title(titlu, fontsize=13)
112      ax.legend(handles=legenda, loc="lower center", ncol=len(legenda), frameon=False,
113                bbox_to_anchor=(0.5, -0.02), fontsize=10)
114      fig.tight_layout()
115      fig.savefig(f"{folder_iesire}/{fisier_png}", dpi=100)
116      plt.close(fig)
117
118
119  def frunza_clasificare(ax, x, y_frunze, nod):
120      """Bara stivuită din frunză: din ce clase sunt pachetele."""
121      baza = y_frunze - 1.75
122      for clasa, culoare in CULORI_CLASE.items():
123          inaltime = 1.6 * nod[clasa] / nod.n
124          ax.add_patch(Rectangle((x - 0.25, baza), 0.5, inaltime, fc=culoare, ec="white", lw=0.8))
125          baza += inaltime
126      procent_atac = 100 * (1 - nod.legitimate / nod.n)
127      ax.text(x, y_frunze - 2.0, f"n = {format_zecimale(nod.n, 0)}\natac {format_zecimale(procent_atac, 1)}%",
128              ha="center", va="top", fontsize=9)
129
130
131  def inaltime_log(valoare):
132      """Scară logaritmică pentru tcp.len, de la 0 la 32768 (maximul tcp.len) pe 1,6 unități."""
133      return 1.6 * np.log10(1 + valoare) / np.log10(1 + 32768)
134
135
136  def frunza_regresie(ax, x, y_frunze, nod):
137      """Boxplot tcp.len în frunză: minim-maxim, Q1-Q3, mediana, media (valoarea prezisă)."""
138      baza = y_frunze - 1.75
139      ax.plot([x, x], [baza + inaltime_log(nod["0%"]), baza + inaltime_log(nod["100%"])], color="#444", lw=1)
140      # înălțime minimă, ca o cutie cu Q1 = Q3 să rămână vizibilă
141      inaltime_cutie = max(inaltime_log(nod["75%"]) - inaltime_log(nod["25%"]), 0.004)
142      ax.add_patch(Rectangle((x - 0.2, baza + inaltime_log(nod["25%"])), 0.4, inaltime_cutie, fc="#cfe2fb", ec
```

```
="#2a7ad6"))
    ax.plot([x - 0.2, x + 0.2], [baza + inaltime_log(nod["50%"])] * 2, color="#123f80", lw=2.5)
    ax.plot(x, baza + inaltime_log(nod.media), "D", color="#e8692f", ms=6)
    ax.text(x, y_frunze - 2.0, f"n = {format_zecimale(nod.n, 0)}\nmedia {format_zecimale(nod.media, 1)}",
            ha="center", va="top", fontsize=9)
    if x == 0:  # axa tcp.len, o singură dată, lângă prima frunză
        for valoare in [0, 10, 100, 1000, 10000]:
            ax.text(-0.55, baza + inaltime_log(valoare), format_zecimale(valoare, 0), ha="right", va="cente
r",
                    fontsize=8, color="#666")
            ax.plot([-0.52, -0.47], [baza + inaltime_log(valoare)] * 2, color="#666", lw=1)
        ax.plot([-0.5, -0.5], [baza, baza + 1.6], color="#666", lw=1)
        ax.text(-0.5, baza + 1.7, "tcp.len", ha="center", fontsize=8, color="#666")


# ---------------------------------------------------------------------------
# 10.4 și 10.6: cei doi arbori
# ---------------------------------------------------------------------------

deseneaza_arbore(f"{folder_csv}/noduri_clasificare.csv", "Arborele de clasificare (is_attack), maxdepth =
5",
                 "arbore_clasificare.png", frunza_clasificare,
                 [Patch(fc=culoare, label=clasa) for clasa, culoare in CULORI_CLASE.items()])
deseneaza_arbore(f"{folder_csv}/noduri_regresie.csv", "Arborele de regresie (tcp.len), maxdepth = 4",
                 "arbore_regresie.png", frunza_regresie,
                 [Patch(fc="#cfe2fb", ec="#2a7ad6", label="Q1 până la Q3"),
                  Line2D([], [], color="#123f80", lw=2.5, label="mediana"),
                  Line2D([], [], marker="D", color="#e8692f", ls="", label="media (valoarea prezisă)")])


# ---------------------------------------------------------------------------
# 10.3: alegerea adâncimii maxime
# ---------------------------------------------------------------------------

clasificare = pd.read_csv(f"{folder_csv}/adancime_clasificare.csv")
regresie = pd.read_csv(f"{folder_csv}/adancime_regresie.csv")
adancimi = clasificare.maxdepth
# (valori pe toate pachetele, titlu, adâncimea aleasă)
panouri = [(clasificare.f1, "Arborele de clasificare: F1", 5),
           (regresie.R2, "Arborele de regresie: R²", 4)]

fig, axs = plt.subplots(1, 2, figsize=(15.3, 5.78))
for ax, (valori, titlu, aleasa) in zip(axs, panouri):
    ax.plot(adancimi, valori, "o-", color="#2a7ad6", lw=2.5, ms=8)
    for adancime, valoare in zip(adancimi, valori):
        ax.annotate(format_zecimale(valoare, 3), (adancime, valoare), textcoords="offset points", xytext=(0,
-16),
                    ha="center", fontsize=9)
    ax.axvline(aleasa, color="gray", ls=":")
    ax.text(aleasa + 0.08, ax.get_ylim()[0], f"ales: {aleasa}", color="gray", va="bottom")
    ax.set_title(titlu)
    ax.set_xlabel("maxdepth")
    ax.set_xticks(adancimi)
    ax.yaxis.set_major_formatter(lambda v, _: format_scurt(round(v, 3)))
    ax.grid(axis="y", alpha=0.3)
    ax.spines[["top", "right"]].set_visible(False)
fig.tight_layout()
fig.savefig(f"{folder_iesire}/adancime.png", dpi=100)
plt.close(fig)
```